

# Statistik II

---

## Einheit 6: Multiple Regression

Wintersemester 2025 | Prof. Dr. Stephan Goerigk


## Vorbemerkungen

- multiple Regression: das Regressionsmodell enthält mehr als eine UV (Prädiktor)
- Ziel: Durch Hinzunahme weiterer Prädiktoren Vorhersagen bezogen auf die AV zu verbessern


## Abgrenzung zur mehrfaktoriellen ANOVA:

- Bei der ANOVA sind UVs immer kategorial (Mittelwertesvergleiche zw. Gruppen/Kategorien)
- Im Regressionsmodell können kategoriale und stetige UVs verwendet und auch kombiniert werden

### Einfaktorielles Modell:




### Mehrfaktorielles Modell:




## Weitere relevante Fragen

- Wie viel % der Gesamtvarianz der AV können die Prädiktoren **gemeinsam** erklären?
- Welcher Prädiktor hat den **größten** Vorhersagebeitrag?
- **Verändert** sich die Stärke, Richtung (und Interpretation) des Effekts eines Prädiktors, wenn weitere Prädiktoren berücksichtigt werden? (z.B. Überdeckungseffekte)

### Einfaktorielles Modell:



### Mehrfaktorielles Modell:



## Szenario in der Vorlesung

Wir beschränken uns heute zunächst auf die einfachste Form der multiplen Regression:

- Die Beschreibung des AV-Werts  $Y_i$  durch 2 stetige Prädiktoren und die Fehlervariable.
- Hat man den Fall mit zwei Prädiktoren verstanden, ist die Generalisierung auf weitere Prädiktoren einfach.

Dies lässt sich durch die folgende **Erweiterung der Regressionsgleichung** darstellen:

$$Y_i = a + b_1 \cdot X_{i1} + b_2 \cdot X_{i2} + \epsilon_i$$

wobei:

$$\epsilon_i \sim N(0, \sigma^2)$$


(Fehler normalverteilt mit Erwartungswert 0)

## Elemente der multiplen Regressionsgleichung

$$Y_i = a + b_1 \cdot X_{i1} + b_2 \cdot X_{i2} + \epsilon_i$$


- $X_1$  und  $X_2$  sind Zufallsvariablen. Ihre Realisationen sind jeweils die Werte der zufällig gezogenen Person  $i$  bezüglich der  $UV_1$  und der  $UV_2$
- $a, b_1, b_2$  und  $\sigma^2$  sind die zu schätzenden Modellparameter
  - $a$  = Y-Achsenabschnitt
  - $b_1$  = Steigungsparameter der  $UV_1$
  - $b_2$  = Steigungsparameter der  $UV_2$
  - $\sigma^2$  = Varianz des Fehlerterms (für Hypothesen meist inhaltlich nicht relevant)

## Graphische Darstellung



- Einfache lineare Regression: 2-dimensionales Koordinatensystem mit X-Achse und Y-Achse
  - Multiple Regression (2 UVs): 3-dimensionales Koordinatensystem mit X-Achse, Y-Achse und Z-Achse
- Es wird ein 3D-Streudiagramm dargestellt
- Punkt = Beobachtungswert einer Person
  - Kombination aus  $AV$  (Y-Achse),  $UV_1$  (X-Achse) und  $UV_2$  (Z-Achse) Wert


## Graphische Darstellung



- Einfache lineare Regression: Modellfunktion dargestellt durch Regressionsgerade
  - Gerade definiert durch 1 Y-Achsenabschnitt + 1 Steigungsparameter
- Multiple Regression (2 UVs): Modellfunktion dargestellt durch Regressionsebene
  - Ebene definiert durch 1 Y-Achsenabschnitt + 2 Steigungsparameter
- Auf der Ebene liegen alle durch das Modell erwarteten Werte

## Graphische Darstellung


$$Y_i = a + b_1 \cdot X_{i1} + b_2 \cdot X_{i2} + \epsilon_i$$



- $a$  gibt den Y-Achsenabschnitt an
  - $a$  ist der Wert der AV, wenn  $UV_1$  und  $UV_2$  gleich 0 sind
  - $a = a + b_1 \cdot 0 + b_2 \cdot 0$
  - Ob  $a$  sinnvoll interpretiert werden kann, hängt davon ab, ob  $UV_1 = 0$  und  $UV_2 = 0$  inhaltlich sinnvolle Werte darstellen
- $b_1$  gibt an, wie stark die Regressionsebene auf der  $xy$ -Gerade steigt bzw. fällt, wenn  $UV_1$  um 1 Einheit zunimmt.
- $b_2$  gibt an, wie stark die Regressionsebene auf der  $zy$ -Gerade steigt bzw. fällt, wenn  $UV_2$  um 1 Einheit zunimmt.



## Parameterschätzung



- Die unbekannten Modellparameter  $a$ ,  $b_1$  und  $b_2$  können mit der **Methode der kleinsten Quadrate** bestimmt werden (wie bei einfacher Regression)
- Die Ebene wird so definiert, dass die Residuen minimiert werden
- Die Formeln sind aufwendig, weswegen wir uns hier auf die Berechnung in R beschränken

## Standardfehler der Modellparameter

- Während wir die Schätzung der Modellparameter R überlassen, schauen wir uns einmal die Berechnung der Standardfehler für  $b_1$  und  $b_2$  an.
- Diese brauchen wir, um Hypothesentests/Konfidenzintervalle für diese Parameter zu berechnen

$$SE(B_1) = \sqrt{Var(B_1)} = \sqrt{\frac{1}{1 - r_{x_1x_2}^2} \cdot \frac{\sigma^2}{\sum_{i=1}^n (x_{i1} - \bar{x}_1)^2}}$$

$$SE(B_2) = \sqrt{Var(B_2)} = \sqrt{\frac{1}{1 - r_{x_1x_2}^2} \cdot \frac{\sigma^2}{\sum_{i=1}^n (x_{i2} - \bar{x}_2)^2}}$$

- $r_{x_1x_2}^2$  stellt die quadrierte Korrelation zwischen den beiden Prädiktoren dar
- $\sigma^2$  wird durch die Stichprobenvarianz  $s^2$  geschätzt.

## Konfidenzintervalle der Modellparameter

Die Konfidenzintervalle für  $b_1$  und  $b_2$  lassen sich wie folgt berechnen:

$$b \pm t_{1-\frac{\alpha}{2}} \cdot SE(B_j)$$

- Die Freiheitsgrade für den t-Wert errechnen sich als  $df = n - 3$

## Beispiel: Risikofaktoren für Aggression bei Kindern

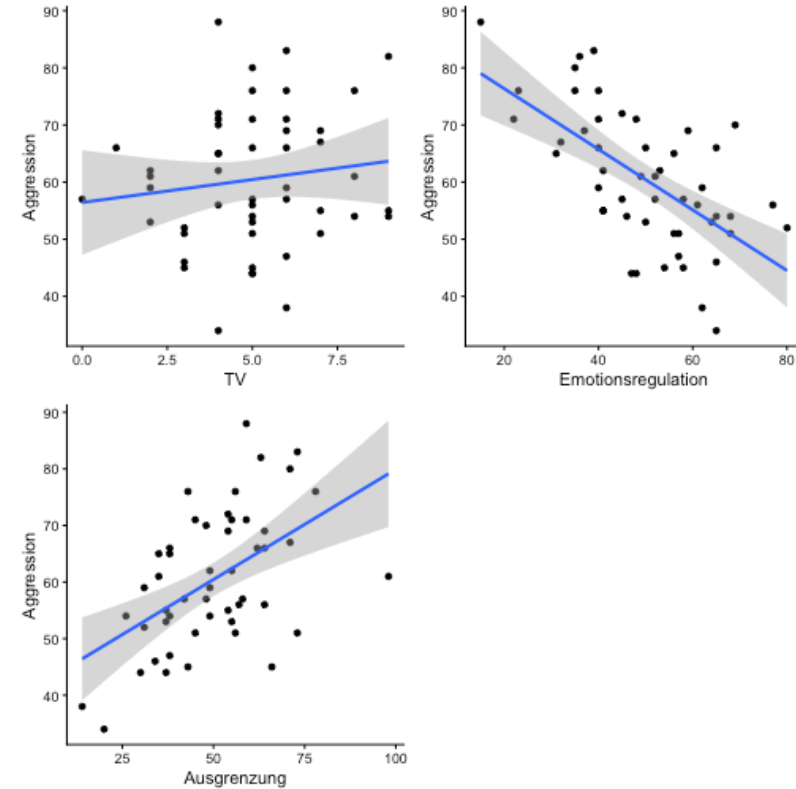
- Wissenschaftler:innen haben Daten erhoben ( $N = 50$ ), um Risikofaktoren für Aggression bei Kindern zu identifizieren.
- Folgende Variablen wurden gemessen
  - Aggression (AV, 1-100 Punkte)
  - TV (UV, in Stunden/Tag)
  - Emotionsregulation (UV, 1-100 Punkte)
  - Ausgrenzungserfahrung (UV, 1-100 Punkte)
- Die ersten 15 Fälle sind in der Tabelle rechts dargestellt.

Aggression	TV	Emotionsregulation	Ausgrenzung
53	5	50	55
57	5	58	58
80	5	35	71
61	8	49	35
62	4	41	49
82	9	36	63
66	1	40	62
44	5	47	30
51	5	56	56
54	5	68	38
76	6	35	78
65	4	56	38
65	4	31	35
61	2	52	98
53	2	64	37

# Multiple Regression

## Beispiel: Risikofaktoren für Aggression bei Kindern

- Um einen 1. Eindruck zu gewinnen, lohnt es sich, die Daten zu visualisieren
- Wir schauen uns dafür die bivariaten Streudiagramme an:



## Modellschätzung in R

```
model = lm(Aggression ~ TV + Emotionsregulation, data = df)
summary(model)
```

```
##
## Call:
## lm(formula = Aggression ~ TV + Emotionsregulation, data = df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -18.4040  -6.2847   0.7681   7.6023  19.7061
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   86.24294     6.70484  12.863 < 0.0000000000000002 ***
## TV             0.11254     0.68819   0.164    0.871
## Emotionsregulation -0.52752     0.09961  -5.296  0.00000308 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 9.604 on 47 degrees of freedom
## Multiple R-squared:  0.3852,    Adjusted R-squared:  0.3591
## F-statistic: 14.73 on 2 and 47 DF,  p-value: 0.00001083
```

Die Schätzwerte für  $a$ ,  $b_1$  und  $b_2$  können in der Spalte **Estimate** abgelesen werden

### Interpretation:

- Der durchschnittliche Aggressionswert eines Kindes, das 0h TV sieht und einen Emotionsregulationsscore von 0 hat ist  $a = 86.24$
- Mit jeder zusätzlichen Stunde TV nimmt der Aggressionswert um  $b_1 = 0.11$  Punkte zu.
- Mit jedem zusätzlichen Punkt auf der Emotionsregulationsskala nimmt der Aggressionswert um  $b_2 = -0.53$  Punkte ab.

## Schätzung der unbekannten Fehlervarianz $\sigma^2$

Die Schätzfunktion für die unbekannte Fehlervarianz lässt sich darstellen als

$$\hat{\sigma}^2 = \frac{1}{n-3} \sum_{i=1}^n (Y_i - (A + B_1 \cdot X_{i2}))^2$$

- Nach Umstellen und ziehen der Wurzel erhält man den Standardschätzfehler (wie in der einfachen Regression):

$$s = \sqrt{\frac{\sum_{i=1}^n e_i^2}{n-3}}$$

→ Dies entspricht der Wurzel aus der Summe der quadrierten Residuen geteilt durch  $n - 3$

## Schätzung der unbekannten Fehlervarianz $\sigma^2$

```
model = lm(Aggression ~ TV + Emotionsregulation, data = df)
summary(model)
```

```
##
## Call:
## lm(formula = Aggression ~ TV + Emotionsregulation, data = df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -18.4040  -6.2847   0.7681   7.6023  19.7061
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    86.24294     6.70484  12.863 < 0.0000000000000002 ***
## TV              0.11254     0.68819   0.164    0.871
## Emotionsregulation -0.52752     0.09961  -5.296  0.00000308 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 9.604 on 47 degrees of freedom
## Multiple R-squared:  0.3852,    Adjusted R-squared:  0.3591
## F-statistic: 14.73 on 2 and 47 DF,  p-value: 0.00001083
```

Dieser Wert findet sich im unteren Bereich des R Outputs:

$$s = \sqrt{\frac{\sum_{i=1}^n e_i^2}{n-3}} = 9.60$$



## Aufstellen der Modellgleichung

```
model = lm(Aggression ~ TV + Emotionsregulation, data = df)
summary(model)
```

```
##
## Call:
## lm(formula = Aggression ~ TV + Emotionsregulation, data = df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -18.4040  -6.2847   0.7681   7.6023  19.7061
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept)    86.24294     6.70484  12.863 < 0.0000000000000002 ***
## TV              0.11254     0.68819   0.164      0.871
## Emotionsregulation -0.52752     0.09961  -5.296    0.00000308 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 9.604 on 47 degrees of freedom
## Multiple R-squared:  0.3852,    Adjusted R-squared:  0.3591
## F-statistic: 14.73 on 2 and 47 DF,  p-value: 0.00001083
```

Allgemeine Form:

$$Y_i = a + b_1 \cdot X_{i1} + b_2 \cdot X_{i2} + \epsilon_i$$

mit  $\epsilon_i \sim N(0, \sigma^2)$

In unserem Fall ergibt sich die Modellgleichung:

$$Y_i = 86.24 + 0.11 \cdot X_{i1} + -0.53 \cdot X_{i2} + \epsilon_i$$

mit  $\epsilon_i \sim N(0, 9.60^2)$

→ Damit ließe sich ein konkreter Wert  $Y_i$  der AV schätzen.

## Hypothesentests

Je nach konkreter Fragestellung muss entschieden werden, welche Parameter geschätzt werden sollen bzw. welche Hypothesen getestet werden sollen.

Wir besprechen (zunächst) zwei Arten von Hypothesentests für die multiple Regression:

### 1. Hypothesentests für einzelne Modellparameter (z.B. eine Steigung)

- $H_0 : b_j = 0$
- Geeignet für Zusammenhangshypothesen
- keine Steigung = kein Zusammenhang (UV kann AV nicht systematisch vorhersagen)

### 2. Omnibus Tests

- basieren auf Vergleich der Varianzaufklärung (wie ANOVA)
- prüfen Signifikanz des Gesamtmodells ( $H_0$  : alle Steigungen sind 0)
- erlauben Vergleich von Teilmodellen (z.B. Modell mit weiterem Prädiktor vs. Modell ohne weiteren Prädiktor)

## Hypothesentests für einzelne Modellparameter

```
model = lm(Aggression ~ TV + Emotionsregulation, data = df)
summary(model)
```

```
##
## Call:
## lm(formula = Aggression ~ TV + Emotionsregulation, data = df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -18.4040  -6.2847   0.7681   7.6023  19.7061
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept)   86.24294     6.70484  12.863 < 0.0000000000000002 ***
## TV             0.11254     0.68819   0.164      0.871
## Emotionsregulation -0.52752     0.09961  -5.296    0.00000308 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 9.604 on 47 degrees of freedom
## Multiple R-squared:  0.3852,    Adjusted R-squared:  0.3591
## F-statistic: 14.73 on 2 and 47 DF,  p-value: 0.00001083
```

**Unser Beispiel:** Es soll überprüft werden, ob TV-Sehen bzw. Emotionsregulation linear mit Aggression zusammenhängt, wenn der jeweils andere Prädiktor konstant gehalten wird.

### 1. Hypothesentest Y-Achsenabschnitt:

- $H_0 : a = 0$
- $H_1 : a \neq 0$

### 2. Hypothesentest Steigung (TV):

- $H_0 : b_1 = 0$
- $H_1 : b_1 \neq 0$

### 3. Hypothesentest Steigung (Emotionsregulation):

- $H_0 : b_2 = 0$
- $H_1 : b_2 \neq 0$

## Hypothesentests für einzelne Modellparameter

```
model = lm(Aggression ~ TV + Emotionsregulation, data = df)
summary(model)
```

```
##
## Call:
## lm(formula = Aggression ~ TV + Emotionsregulation, data = df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -18.4040  -6.2847   0.7681   7.6023  19.7061
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept)    86.24294     6.70484  12.863 < 0.0000000000000002 ***
## TV              0.11254     0.68819   0.164      0.871
## Emotionsregulation -0.52752     0.09961  -5.296    0.00000308 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 9.604 on 47 degrees of freedom
## Multiple R-squared:  0.3852,    Adjusted R-squared:  0.3591
## F-statistic: 14.73 on 2 and 47 DF,  p-value: 0.00001083
```

$$t_a = \frac{a}{SE(a)} = \frac{86.24}{6.70} = 12.86$$

$$t_{b_1} = \frac{b_1}{SE(b_1)} = \frac{0.11}{0.69} = 0.16$$

$$t_{b_2} = \frac{b_2}{SE(b_2)} = \frac{-0.53}{0.10} = -5.30$$

- Unter der Geltung der  $H_0$  folgen diese Teststatistiken jeweils einer t-Verteilung mit  $df = n - 3$
- Der kritische Bereich ist jeweils beidseitig.
- $p$ -Werte  $< .05$  zeigen signifikantes Ergebnis an (Koeffizient  $\neq 0$ )

## Hypothesentests für einzelne Modellparameter - Konfidenzintervalle

```
model = lm(Aggression ~ TV + Emotionsregulation, data = df)
summary(model)
```

```
##
## Call:
## lm(formula = Aggression ~ TV + Emotionsregulation, data = df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -18.4040  -6.2847   0.7681   7.6023  19.7061
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept)    86.24294     6.70484  12.863 < 0.0000000000000002 ***
## TV              0.11254     0.68819   0.164      0.871
## Emotionsregulation -0.52752     0.09961  -5.296    0.00000308 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 9.604 on 47 degrees of freedom
## Multiple R-squared:  0.3852,    Adjusted R-squared:  0.3591
## F-statistic: 14.73 on 2 and 47 DF,  p-value: 0.00001083
```

```
confint(model)
```

```
##              2.5 %      97.5 %
## (Intercept)  72.7545432  99.7313311
## TV          -1.2719190   1.4970047
## Emotionsregulation -0.7279233 -0.3271248
```

- KI zeigt Bereich an, in welchem der Parameter mit 95% Sicherheit liegt.
- Umschließt KI die 0 nicht (Koeffizient ungleich 0), kommt dies einem signifikanten Testergebnis gleich

## Omnibus-Test

Omnibustest des Gesamtmodells kann folgende Hypothese prüfen:

- $H_0 : b_1 = b_2 = 0$
- $H_1 : b_j \neq 0$

→ Mithilfe des Omnibus-Tests kann überprüft werden, ob bei zumindest einer der UVs der lineare Zusammenhang mit der AV ungleich 0 ist (bei Konstanthaltung der jeweils anderen UV).

## Anders gesagt:

- Prüfung, ob Modell mit Prädiktoren signifikant mehr Varianz der AV erklärt als ohne.
- Es werden Varianzen verwendet → Teststatistik ist wieder der von der ANOVA bekannte F-Wert

## Omnibus-Test

Die Teststatistik des Omnibus-Tests ist wie folgt definiert:

$$F = \frac{\frac{1}{2} \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{\frac{1}{n-3} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2} = \frac{\frac{1}{2} \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{s^2}$$

- Unter der Geltung der Nullhypothese folgt diese Teststatistik einer F-Verteilung.
- Der kritische Bereich liegt auf der rechten Seite.

## Omnibus-Test

```
model = lm(Aggression ~ TV + Emotionsregulation, data = df)
summary(model)
```

```
##
## Call:
## lm(formula = Aggression ~ TV + Emotionsregulation, data = df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -18.4040  -6.2847   0.7681   7.6023  19.7061
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    86.24294     6.70484  12.863 < 0.0000000000000002 ***
## TV              0.11254     0.68819   0.164    0.871
## Emotionsregulation -0.52752     0.09961  -5.296  0.00000308 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 9.604 on 47 degrees of freedom
## Multiple R-squared:  0.3852,    Adjusted R-squared:  0.3591
## F-statistic: 14.73 on 2 and 47 DF,  p-value: 0.00001083
```

Dieser Wert findet sich im unteren Bereich des R Outputs:

$$F = \frac{\frac{1}{2} \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{s^2} = 14.73$$

mit  $df_{\text{Zähler}} = 2$  und  $df_{\text{Nenner}} = 47$

- $p = 0.00001083 < .05$
- Das Gesamtmodell mit den Prädiktoren erklärt signifikant mehr Varianz, als das Modell ohne Prädiktoren.



## Omnibus-Test - Modellvergleiche

- Der Omnibus-Test ermöglicht uns auch den Vergleich von 2 Modellen miteinander
- Voraussetzung ist, dass das eine Modell (komplex) das andere Modell (einfach) enthält (geschachtelte Modelle; engl.: "*nested models*").
- Dies z.B. der Fall, wenn wir zu einem bestehenden Modell einen Prädiktor hinzunehmen
- Wir probieren dies in unserem Beispiel, indem wir zu unserem Modell den Prädiktor "Ausgrenzungserfahrung" hinzunehmen
  - **Szenario 1:** Ausgrenzungserfahrung ist kein relevanter Prädiktor - Modell ohne Ausgrenzungserfahrung erklärt Daten zumindest gleich gut
  - **Szenario 2:** Modell mit Ausgrenzungserfahrung hat signifikant bessere Modellpassung (kann AV besser vorhersagen)

## Omnibus-Test - Modellvergleiche

```
# Aufstellen einfaches Modell:
modell = lm(Aggression ~ TV + Emotionsregulation, data = df)

# Aufstellen komplexes Modell:
modell2 = lm(Aggression ~ TV + Emotionsregulation + Ausgrenzung, data = df)

# Das einfache Modell ist in das komplexe Modell "geschachtelt"
```

```
# Omnibus-Test zum Vergleich "geschachtelter" Modelle
anova(modell1, modell2)

## Analysis of Variance Table
##
## Model 1: Aggression ~ TV + Emotionsregulation
## Model 2: Aggression ~ TV + Emotionsregulation + Ausgrenzung
##   Res.Df  RSS Df Sum of Sq    F    Pr(>F)
## 1      47 4335.5
## 2      46 3508.3   1    827.2 10.846 0.001909 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Das komplexe Modell (inklusive Prädiktor Ausgrenzung) kann AV signifikant besser vorhersagen als das einfache Modell ( $p = 0.001909 < .05$ )

## Hinzunahme weiterer Prädiktoren

*# Aufstellen einfaches Modell:*

```
modell = lm(Aggression ~ TV + Emotionsregulation, data = df)
summary(modell)
```

```
##
## Call:
## lm(formula = Aggression ~ TV + Emotionsregulation, data = df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -18.4040  -6.2847   0.7681   7.6023  19.7061
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept)    86.24294     6.70484  12.863 < 0.0000000000000002 ***
## TV              0.11254     0.68819   0.164      0.871
## Emotionsregulation -0.52752     0.09961  -5.296    0.00000308 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 9.604 on 47 degrees of freedom
## Multiple R-squared:  0.3852,    Adjusted R-squared:  0.3591
## F-statistic: 14.73 on 2 and 47 DF,  p-value: 0.00001083
```

*# Aufstellen komplexes Modell:*

```
model2 = lm(Aggression ~ TV + Emotionsregulation + Ausgrenzung, data = df)
summary(model2)
```

```
##
## Call:
## lm(formula = Aggression ~ TV + Emotionsregulation + Ausgrenzung,
##      data = df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -15.6668  -7.6041   0.2665   6.8444  18.4565
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept)    65.59233     8.74569   7.500 0.000000000163 ***
## TV              0.40650     0.63209   0.643   0.52335
## Emotionsregulation -0.41784     0.09651  -4.330 0.00007997688 ***
## Ausgrenzung      0.27409     0.08322   3.293   0.00191 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 8.733 on 46 degrees of freedom
## Multiple R-squared:  0.5025,    Adjusted R-squared:  0.4701
## F-statistic: 15.49 on 3 and 46 DF,  p-value: 0.0000004219
```

## Hinzunahme weiterer Prädiktoren

Was passiert?

- Weiterer Prädiktor wird an Modell "drangehängt"
- Er erhält ebenfalls einen Steigungsparameter, dieser erhält einen Signifikanztest
  - Mit weiterem Punkt Ausgrenzungserfahrung nimmt Aggression um  $b_3 = 0.27$  Punkte zu
  - Ausgrenzungserfahrung kann Aggression signifikant vorhersagen ( $p = 0.00191$ )
- Y-Achsenabschnitt ist nun der Wert der AV, wenn alle 3 Prädiktoren = 0 sind.

```
# Aufstellen komplexes Modell:
```

```
model2 = lm(Aggression ~ TV + Emotionsregulation + Ausgrenzung, data = df)
summary(model2)
```

```
##
## Call:
## lm(formula = Aggression ~ TV + Emotionsregulation + Ausgrenzung,
##     data = df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -15.6668  -7.6041   0.2665   6.8444  18.4565
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept)    65.59233     8.74569   7.500 0.00000000163 ***
## TV              0.40650     0.63209   0.643   0.52335
## Emotionsregulation -0.41784     0.09651  -4.330 0.00007997688 ***
## Ausgrenzung     0.27409     0.08322   3.293   0.00191 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 8.733 on 46 degrees of freedom
## Multiple R-squared:  0.5025,    Adjusted R-squared:  0.4701
## F-statistic: 15.49 on 3 and 46 DF,  p-value: 0.0000004219
```

## Modellpassung

- Auch für die multiple Regression lässt sich die Güte des Modells über  $R^2$  schätzen
- Zur Erinnerung:
  - Verhältnis aufgeklärter zu gesamter Streuung
  - $0 \leq R^2 \leq 1$
  - Je näher  $R^2$  an 1, desto besser passt sich Modell an Beobachtungspunkte an
- Die Hinzunahme weiterer Prädiktoren erhöht i.d.R. die Modellpassung

## Modellpassung

```
##
## Call:
## lm(formula = Aggression ~ TV + Emotionsregulation, data = df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -18.4040  -6.2847   0.7681   7.6023  19.7061
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept)    86.24294     6.70484  12.863 < 0.0000000000000002 ***
## TV              0.11254     0.68819   0.164      0.871
## Emotionsregulation -0.52752     0.09961  -5.296    0.00000308 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 9.604 on 47 degrees of freedom
## Multiple R-squared:  0.3852,    Adjusted R-squared:  0.3591
## F-statistic: 14.73 on 2 and 47 DF,  p-value: 0.00001083
```

```
##
## Call:
## lm(formula = Aggression ~ TV + Emotionsregulation + Ausgrenzung,
##     data = df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -15.6668  -7.6041   0.2665   6.8444  18.4565
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept)    65.59233     8.74569   7.500 0.000000000163 ***
## TV              0.40650     0.63209   0.643   0.52335
## Emotionsregulation -0.41784     0.09651  -4.330 0.00007997688 ***
## Ausgrenzung      0.27409     0.08322   3.293   0.00191 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 8.733 on 46 degrees of freedom
## Multiple R-squared:  0.5025,    Adjusted R-squared:  0.4701
## F-statistic: 15.49 on 3 and 46 DF,  p-value: 0.000004219
```

- Einfaches Modell (links):  $R^2 = .39 \rightarrow$  Es können 39% der AV (Aggression) durch TV und Emotionsregulation erklärt werden.
- Komplexes Modell (rechts):  $R^2 = .50 \rightarrow$  Es können weitere 11% der AV durch Ausgrenzung erklärt werden.

## Vorhersagewerte - Anwendung des Modells

$$Y_i = 86.24 + 0.11 \cdot X_{i1} + -0.53 \cdot X_{i2} + \epsilon_i$$

- Mit der aufgestellten Modellgleichung, können wir Werte vorhersagen.

**Beispiel** für Person  $i = 1$ :

$$\hat{Y}_i = 86.24294 + 0.11254 \cdot 5 + -0.52752 \cdot 50 = 60.43$$

- Laut unserem Modell mit 2 Prädiktoren, sollte Person 1 einen Aggressionswert von 60.29 Punkten haben.
- Da der tatsächlich beobachtete Wert 53 ist, beträgt der Modellfehler  $60.29 - 53 = 7.29$  Punkte.

Aggression	TV	Emotionsregulation	Ausgrenzung
53	5	50	55
57	5	58	58
80	5	35	71
61	8	49	35
62	4	41	49
82	9	36	63
66	1	40	62
44	5	47	30
51	5	56	56
54	5	68	38
76	6	35	78
65	4	56	38
65	4	31	35
61	2	52	98
53	2	64	37

## Vorhersagewerte - Anwendung des Modells

Wir können mit R automatisch die Wert für unsere Modelle schätzen:

Für das Modell mit TV und Emotionsregulation:

```
df$pred_model1 = round(predict(model1, newdata = df), 2)
```

Für das Modell mit TV, Emotionsregulation und Ausgrenzung:


```
df$pred_model2 = round(predict(model2, newdata = df), 2)
```

Aggression	TV	Emotionsregulation	Ausgrenzung	pred_model1	pred_model2
53	5	50	55	60.43	61.81
57	5	58	58	56.21	59.29
80	5	35	71	68.34	72.46
61	8	49	35	61.29	57.96
62	4	41	49	65.06	63.52
82	9	36	63	68.26	71.48
66	1	40	62	65.25	66.28
44	5	47	30	62.01	56.21
51	5	56	56	57.26	59.57
54	5	68	38	50.93	49.63
76	6	35	78	68.45	74.79
65	4	56	38	57.15	54.23
65	4	31	35	70.34	63.86
61	2	52	98	59.04	71.54
53	2	64	37	52.71	49.80



## Vorhersagewerte - Anwendung des Modells

- Je besser das Modell passt, desto stärker der Zusammenhang zwischen beobachteten und vorhergesagten Werten:



## Voraussetzungen der multiplen Regression

### Wie bei einfacher Regression:

- 1) Das Kriterium (AV) muss intervallskaliert und normalverteilt sein.
- 2) Die Prädiktoren (UV) können entweder intervallskaliert und normalverteilt oder dichotom nominalskaliert sein.
- 3) Die Werte der einzelnen Versuchspersonen müssen unabhängig voneinander sein
- 4) Die Zusammenhänge müssen theoretisch linear sein (sonst andere Regressionsmodelle nutzen).
- 5) Streuungen der Wertepaare müssen über ganzen Wertebereich von  $X$  und  $Z$  homogen sein (Homoskedastizität).


### Nur bei multipler Regression:

- 6) Multikollinearität: Prädiktoren sollten nicht zu stark miteinander korrelieren

## Voraussetzungen der multiplen Regression

### Normalverteilung der Residuen:

```
qqnorm(rstandard(model1), cex = 1.5)  
qqline(rstandard(model1))
```



```
model1 = lm(Aggression ~ TV + Emotionsregulation, data = df)  
shapiro.test(rstandard(model1))
```

```
##  
##      Shapiro-Wilk normality test  
##  
## data:  rstandard(model1)  
## W = 0.98337, p-value = 0.6997
```


### Benchmarks:

- QQ-Plot: Punkte sollten möglichst auf der 45 Grad Diagonalen liegen
- Shapiro-Wilk Test: p-Wert sollte  $> \alpha = .05$  sein

## Voraussetzungen der multiplen Regression

### Homoskedastizität:

```
modell = lm(Aggression ~ TV + Emotionsregulation, data =  
plot(modell, 1, cex = 2)
```



- Plot der standardisierten Residuen gegen die standardisierten vorhergesagten Werte
  - Ideal ist eine Punktwolke ohne Systematik (Pattern)
  - Die Linie sollte relativ horizontal verlaufen
- dann ist Homoskedastizitätsannahme gegeben

## Voraussetzungen der multiplen Regression

### Multikollinearität:

Drei Methoden zur Prüfung von Multikollinearität:

- Korrelationsmatrix für hohe Korrelationen scannen
- Variance inflation factor (VIF)
- Toleranz-Statistik (1/VIF)

Benchmarks für potentielle Multikollinearitätsproblematik:

- Korrelationen mit  $r > .9$  können Probleme bereiten
- größter VIF größer als 10 (Bowerman & O'Connell, 1990)
- Durchschnittlicher VIF substanziell größer als 1
- Toleranz niedriger als 0.1 (ernstes Problem)
- Toleranz niedriger als 0.2 (potentielles Problem)

## Voraussetzungen der multiplen Regression

### Multikollinearität:

Korrelationsmatrix für hohe Korrelationen scannen:

```
cor(df[, c("Aggression", "TV", "Emotionsregulation")])
```

```
##                Aggression          TV Emotionsregulation
## Aggression          1.0000000  0.1357292          -0.6203926
## TV                  0.1357292  1.0000000          -0.1891767
## Emotionsregulation -0.6203926 -0.1891767           1.0000000
```

→ Keine der bivariaten Korrelationen zwischen den Prädiktoren ist  $r > .9$

## Voraussetzungen der multiplen Regression

### Multikollinearität:

VIF und Toleranz berechnen:

```
library(olsrr)

ols_vif_tol(model1)
```

```
##           Variables Tolerance      VIF
## 1              TV 0.9642122 1.037116
## 2 Emotionsregulation 0.9642122 1.037116
```

- Kein VIF größer als 10
- Durchschnittlicher VIF nicht substanziell größer als 1
- Toleranz nicht niedriger als 0.2

→ Es scheint kein Multikollinearitätsproblem vorzuliegen.

- Die Multiple Regression ermöglicht die Erweiterung des Regressionsmodells um **weitere Prädiktoren**.
- Im Gegensatz zur mehrfaktoriellen ANOVA, dürfen **auch stetige UVs** verwendet werden.
- Damit kann die **Modellpassung** und somit die **Vorhersagegüte** erhöht werden.
- Darstellung bei 2 Prädiktoren entspricht einer **Ebene** im 3D Raum.
- Es können **Hypothesentests** für die einzelnen Koeffizienten (Prädiktoren) und für das Gesamtmodell (Omnibustest) geprüft werden.
- Je mehr systematisch prädiktive UVs das Modell enthält, desto eher werden **vorhergesagte Werte** den tatsächlich beobachteten entsprechen.
- Als zusätzliche Modellvoraussetzung muss die **Multikollinearität** geprüft werden